Proyecto 3: Clasificación de tumores en imágenes histopatológicas de cáncer de mama

Eduardo Tello, Abel Escobar, Adrián Sandoval y Luis Romero

I. Introducción

El cáncer de mama es una de las principales causas de morbilidad y mortalidad en mujeres. Según Sung et al. (2021), en 2020 se reportaron unos 2,3 millones de nuevos casos en el mundo, siendo el cáncer más diagnosticado en la población femenina. El diagnóstico temprano sigue basándose en la evaluación histopatológica de biopsias teñidas con hematoxilina y eosina, considerada el estándar de oro.

La interpretación de láminas es un proceso subjetivo, dependiente de la experiencia del patólogo y condicionado por una creciente carga de trabajo. La digitalización de láminas y el avance de la patología computacional han impulsado el uso de modelos de aprendizaje profundo como apoyo diagnóstico. Según Jiang et al. (2024), estos modelos mejoran la segmentación, la clasificación y el pronóstico a partir de imágenes digitales. Dentro de ellos, las redes neuronales convolucionales (CNN) destacan por aprender de forma automática patrones de textura y morfología celular, sin necesidad de extraer características manualmente. Según Zhu et al. (2023), las CNN son una de las herramientas más utilizadas en sistemas de diagnóstico asistido por computadora en cáncer de mama.

En este contexto, el conjunto de datos BreakHis se ha convertido en una referencia para la clasificación automática. Contiene 9 109 imágenes de tejido mamario tumoral de 82 pacientes, divididas en tumores benignos y malignos y capturadas a 40X, 100X, 200X y 400X (Spanhol et al., 2016), lo que permite estudiar tanto la clasificación binaria como el efecto de la magnificación. Estudios como el de Matos et al. (2019), reportan exactitudes cercanas al 90 % con arquitecturas compactas basadas en CNN, aunque persisten problemas de generalización, desbalance de clases e interpretabilidad.

En este informe se desarrollan y evalúan dos modelos de clasificación sobre BreakHis: una CNN tradicional entrenada desde cero y una ResNet18 con *transfer learning*. Se exploran estrategias de preprocesamiento, normalización de tinciones, aumentación avanzada y técnicas para manejar el desbalance de clases. El énfasis se coloca en mejorar la detección de tumores malignos, por su mayor relevancia clínica, sin descuidar el rendimiento en la clase benigna ni en subtipos minoritarios.

II. Análisis exploratorio de datos

El análisis exploratorio de datos (EDA) se realizó utilizando el conjunto de imágenes histopatológicas BreakHis, compuesto por 7 909 imágenes pertenecientes a 81 pacientes. Cada archivo contiene información codificada que permite extraer la clase tumoral, el subtipo, el paciente y el nivel de magnificación.

A. Distribución general de clases

La base de datos presenta un desbalance marcado entre clases: 5 429 imágenes malignas y 2 480 benignas. En la Figura 1 se observa esta diferencia, lo que justifica el uso de técnicas de balanceo durante el entrenamiento.

B. Distribución por magnificación y clase

El conjunto contiene imágenes en cuatro niveles de magnificación: 40X, 100X, 200X y 400X. La Figura 2 muestra que la proporción de imágenes malignas supera de forma consistente a las benignas en todos los niveles.

C. Distribución por paciente

El número de imágenes por paciente es altamente heterogéneo. Algunos pacientes tienen más de 200 imágenes y otros menos de 40. La Figura 3 muestra esta variabilidad y refuerza la necesidad de realizar un *split patient-wise* para evitar fuga de información entre los conjuntos de entrenamiento y prueba.

D. Muestras visuales por clase y magnificación

La Figura 4 presenta ejemplos representativos para cada clase en los cuatro niveles de magnificación. Se observan diferencias claras en estructura celular, densidad, morfología y patrón tisular, lo que respalda el uso de CNN para capturar estas variaciones.

E. Distribución de intensidad promedio

Se analizó la intensidad promedio por imagen para estudiar diferencias de iluminación o coloración. La Figura 5 muestra que las distribuciones de benignos y malignos se superponen, de modo que la intensidad no constituye un atributo discriminante directo. El modelo debe aprender características morfológicas más profundas.

F. Distribución por subtipos tumorales

Los tumores benignos se dividen en F, TA, PT y A, mientras que los malignos incluyen DC, MC, LC y PC. Las Figuras 6 y 7 muestran la distribución por subtipo. Se observa un fuerte desbalance: los subtipos malignos están dominados por *DC* y los benignos por *F*, lo que afecta el rendimiento del modelo sobre subtipos minoritarios como *MC*.

G. Conclusiones del EDA

- Existe un desbalance significativo entre clases, con un número de imágenes malignas que duplica a las benignas.
- El subtipo maligno *MC* es particularmente escaso y difícil de clasificar.
- La heterogeneidad en cantidad de imágenes por paciente exige un *split* estrictamente basado en pacientes.
- Los niveles de magnificación mantienen una distribución consistente entre clases.
- La intensidad promedio no es discriminante, por lo que es necesario explotar patrones morfológicos.
- Las diferencias visuales observadas justifican el uso de técnicas de *data augmentation* avanzadas.

III. Preprocesamiento y acondicionamiento de datos

El conjunto BreakHis presenta desafíos típicos de las imágenes histopatológicas: alta resolución nativa (700×460 píxeles), variaciones de tinción y un desbalance marcado entre clases. Para afrontarlos se definieron dos *pipelines* de preprocesamiento, adaptados a los requerimientos de cada arquitectura.

A. Preprocesamiento para modelo basado en ResNet18

El pipeline de ResNet18 se orientó al *transfer learning*. Se aplicó una partición *patient-wise* mediante *GroupShuffleSplit* en proporciones 70 % entrenamiento, 15 % validación y 15 % prueba, garantizando independencia entre pacientes.

Las imágenes se redimensionaron a 224×224 píxeles y se normalizaron con las estadísticas de ImageNet para aprovechar pesos preentrenados. Durante el entrenamiento se aplicaron recortes aleatorios, rotaciones moderadas, reflexiones y perturbaciones cromáticas. En validación y prueba se usaron transformaciones determinísticas para asegurar reproducibilidad.

Dado el desbalance de clases, se combinó un *WeightedRandomSampler* con pesos inversamente proporcionales a la frecuencia de clase y una función de pérdida ponderada. Esta estrategia fuerza al modelo a ver con mayor frecuencia la clase minoritaria y penaliza con más intensidad sus errores. La normalización de tinciones y las técnicas de aumentación avanzada se detallan en la Sección IV.

B. Preprocesamiento para CNN secuencial profunda

Para la CNN personalizada se buscó reducir el costo computacional y maximizar la extracción de características texturales. Las imágenes se redimensionaron a 128×128 píxeles mediante interpolación bicúbica y se normalizaron en el rango $[0, 1]$ para estabilizar la optimización con *Adam*.

El desbalance entre clases se abordó con *oversampling* aleatorio de la clase benigna en el conjunto de entrenamiento. Además, se incorporó un generador de datos que aplica, de forma dinámica, rotaciones amplias, traslaciones, zoom y volteos horizontales, con el objetivo de mejorar la capacidad de generalización y reducir el sobreajuste.

IV. Metodología

Para el presente trabajo, se desarrollo un pipeline que incluye tecnicas de separación de imágenes *patient-wise*, normalización de tinciones, normalización geométrica y de escala, data augmentation básica y específica para histopatología, balanceo por clase y subtipo, uso de funciones de pérdida robustas al desbalance y comparación de los resultados de las CNN propuestas. A continuación vemos en detalle el enfoque adoptado en puntos clave del trabajo.

A. Normalización de tinciones (método de Macenko)

Las imágenes histopatológicas están fuertemente influenciadas por variaciones en los protocolos de tinción, lo que introduce cambios en el espacio de color sin relevancia biológica. Para reducir esta variabilidad se empleó la normalización de Macenko, que opera en el espacio de densidad óptica (DO):

$$\mathbf{OD} = -\log\left(\frac{\mathbf{I} + \varepsilon}{I_0}\right),$$

donde I_0 es la intensidad máxima y ε un término pequeño. Sobre la matriz $\mathbf{OD}$ se aplica SVD para estimar los vectores de tinciones dominantes, que se utilizan para descomponer cada píxel en concentraciones de hematoxilina y eosina. Estas concentraciones se reescalan respecto a una muestra de referencia y se reconstruye la imagen normalizada en RGB. El objetivo es homogeneizar la apariencia cromática y permitir que el modelo se enfoque en patrones morfológicos.

B. Normalización geométrica y de escala

Para garantizar dimensiones compatibles con las arquitecturas convolucionales se empleó un *resize* con *padding* que preserva la relación de aspecto. Sea una imagen de tamaño $H \times W$ y un tamaño objetivo $S \times S$, se define

$$s = \min\left(\frac{S}{H}, \frac{S}{W}\right),$$

y se obtiene una imagen reescalada de tamaño $H' \times W'$ con *padding* simétrico hasta alcanzar $S \times S$. Este procedimiento conserva las proporciones celulares y tisulares y evita distorsiones geométricas.

C. Transformaciones y data augmentation

1) Data augmentation básica: Se aplicaron transformaciones geométricas e individuales sobre la intensidad que no alteran la estructura microscópica del tejido. A continuación las detallamos:

- `RandomHorizontalFlip` y `RandomRotation` para introducir invariancia a traslaciones y rotaciones moderadas.
- Normalización estándar de ImageNet en los canales RGB, lo que facilita el uso de pesos preentrenados en ResNet18.

2) Aumentación avanzada para histopatología: Para aproximar la variabilidad real de las láminas se añadieron:

- Perturbaciones de brillo y contraste.
- *Color jitter* para simular variaciones de tinción.
- `GaussianBlur` para modelar distintos niveles de enfoque.
- Rotaciones arbitrarias y *flips* horizontales y verticales.

D. Balanceo por clase y subtipo

El desbalance se abordó definiendo pesos combinados por clase y subtipo

$$w_i = w_{\text{class}}\big(c(i)\big) \cdot w_{\text{subtype}}\big(s(i)\big),$$

que se usan dentro de un `WeightedRandomSampler`. De esta forma, muestras de subtipos raros se seleccionan con mayor frecuencia y se reduce el sesgo hacia subtipos mayoritarios.

E. Funciones de pérdida

La pérdida base fue la entropía cruzada ponderada

$$\mathcal{L}_{\text{CE}} = -\sum_{k=1}^{K} w_k \, y_k \log(p_k),$$

combinada, en los experimentos principales, con *Focal Loss*

$$\mathcal{L}_{\text{focal}} = -\sum_{k=1}^{K} \alpha_k \, (1-p_k)^{\gamma} \, y_k \log(p_k),$$

con $\gamma = 2$ y factores α_k proporcionales a la distribución de clases. Esto obliga al modelo a concentrarse en ejemplos difíciles y mejora la sensibilidad en clases minoritarias.

F. Modelos evaluados

1) CNN tradicional entrenada desde cero: La CNN base se compone de bloques convolucionales con activación ReLU y capas de *max-pooling*, seguidos de capas densas para la clasificación binaria. Esta arquitectura sirve como línea base para cuantificar la ganancia obtenida con redes profundas preentrenadas.

2) ResNet18 con transfer learning: El segundo modelo es **ResNet18**, con pesos iniciales de ImageNet. Se reemplazó la capa final por un clasificador binario y se ajustaron las últimas capas mediante *fine-tuning*. Los bloques residuales facilitan el entrenamiento profundo y, combinados con la normalización de tinciones y el balanceo por clase, permiten explotar patrones histológicos de mayor nivel.

G. Esquema Experimental

Para validar las hipótesis del estudio, se definió un diseño experimental comparativo simplificado en dos configuraciones principales:

- **Configuración 1:** Red Convolucional Secuencial (*from scratch*).
  - **Preprocesamiento:** Redimensionamiento a 128×128, normalización [0,1].
  - **Manejo de Desbalance:** Sobremuestreo aleatorio (*Random Oversampling*) en el conjunto de entrenamiento.
  - **Función de Pérdida:** Entropía Cruzada Binaria convencional.
- **Configuración 2 (ResNet18 Transfer Learning):** Arquitectura residual preentrenada en ImageNet.
  - **Preprocesamiento:** Redimensionamiento a 224×224 con *padding* (preservación de aspecto) y normalización estadística de ImageNet.
  - **Manejo de Desbalance:** Muestreo ponderado (*Weighted Random Sampler*) y pesos de clase en la función de costo.
  - **Función de Pérdida:** Entropía Cruzada Ponderada para penalizar fuertemente los falsos negativos.

En ambas configuraciones se mantuvo estrictamente la partición *patient-wise* para asegurar la integridad de la evaluación.

H. Métricas de Evaluación y Agregación por Paciente

La evaluación del rendimiento se realizó en dos niveles de granularidad para medir tanto la capacidad técnica del modelo como su utilidad clínica potencial:

1) Métricas a Nivel de Imagen (Biopsia): Se calcularon las métricas estándar: Exactitud (*Accuracy*), Sensibilidad (*Recall*) y Puntuación F1 (*F1-Score*). Se priorizó el análisis del **AUC-ROC** (Área bajo la Curva ROC) para medir la capacidad de discriminación independiente del umbral de decisión.

2) Métricas a Nivel de Paciente (Clínicas): Dado que un diagnóstico real se basa en múltiples muestras de tejido de un mismo paciente, se implementaron métricas de agregación:

- **Patient Score (PS):** Fracción de imágenes correctamente clasificadas para un paciente específico P_i.
- **Recognition Rate (RR):** El promedio macroscópico de los *Patient Scores* de toda la cohorte de prueba.
- **Winner Takes All (WTA):** Métrica de decisión mayoritaria. Se asigna al paciente la etiqueta de clase (Benigno/Maligno) que tenga más votos entre sus imágenes asociadas. Esta métrica simula el consenso diagnóstico final.

I. Métricas de evaluación y agregación por paciente

A nivel de imagen se utilizaron Accuracy, Recall para malignos, Precision, F1 y AUC. Desde la perspectiva clínica se priorizó la sensibilidad para la clase maligna.

Para capturar la consistencia diagnóstica por paciente, las predicciones de todas las imágenes de un mismo individuo se agregaron mediante voto mayoritario (*Winner Takes All*) o promedio de probabilidades. Sobre estas etiquetas agregadas se calcularon métricas a nivel de paciente como sensibilidad, tasa de reconocimiento y exactitud ponderada.

J. Justificación de la estrategia metodológica

La metodología integra prácticas consolidadas de visión computacional adaptadas al dominio de la histopatología: normalización de tinciones, aumentación avanzada, partición por paciente, balanceo por clase y subtipo, uso de Focal Loss

y comparación entre una CNN desde cero y una red residual preentrenada. El uso combinado de métricas por imagen y por paciente permite evaluar tanto el desempeño global del modelo como su utilidad en un escenario clínico real.

V. Implementación

El desarrollo experimental se llevó a cabo en los entornos de *Google Colab y kaggle* apoyandonos en las GPU T4, especiales para el manejo de tensores. Asimismo, se fijó una semilla global (`42`) en todas las librerías estocásticas para asegurar reproducibilidad. El código fuente, que incluye scripts de preprocesamiento, entrenamiento y análisis, se encuentra disponible en:

https://github.com/Vasco2510/mk-kaggle-notebooks-p3.git

La implementación se realizó con *TensorFlow 2.x* y *Keras*, utilizando generadores de datos para evitar problemas de memoria durante el procesamiento de las 7 909 imágenes.

A. Entrenamiento y scheduling

Se empleó Focal Loss combinada con el esquema de pesos `w = w_class * w_subtype` dentro del *WeightedRandomSampler*. Como referencia se evaluó también entropía cruzada ponderada. El entrenamiento registró métricas por época y se aplicó *early stopping* monitorizando el AUC en validación, junto con esquemas de reducción del *learning rate* (*ReduceLROnPlateau* y *CosineAnnealing*).

B. Configuraciones y evaluación

Cada configuración se entrenó con la misma semilla y se repitió varias veces para estimar la variabilidad. Se calcularon métricas por imagen y por paciente y se generaron curvas ROC, matrices de confusión y mapas Grad-CAM para inspeccionar las regiones de atención del modelo. Los resultados se almacenaron en archivos CSV y se guardaron *checkpoints* con los mejores modelos.

VI. Experimentación

A. Hiperparámetros y criterios de parada

- Optimizador Adam con *learning rate* inicial de $1 \cdot 10^{-4}$ para la cabeza y $1 \cdot 10^{-5}$ en la fase de *fine-tuning*, con $\beta_1 = 0.9$, $\beta_2 = 0.999$ y *weight decay* $1 \cdot 10^{-5}$.
- Tamaño de *batch* entre 16 y 32, según la memoria disponible.
- Entrenamiento hasta 50–100 épocas, con *early stopping* de paciencia 7 sobre el AUC de validación.
- Focal Loss con $\gamma = 2$ y factores α proporcionales a la distribución de clases.

B. Resultados experimentales

Se experimento con data test, que se encuentra en github como "Cancer_test.zip". A continuación observamos en la tabla las metricas que nos permitirán comparar la capacidad de cada red estudiada.

TABLE I: Comparación de Desempeño: CNN Propuesta vs. ResNet18 (Transfer Learning)

Métrica	**CNN propuesta**	**ResNet18 (TL)**
Métricas a Nivel de Imagen		
Exactitud Global (Accuracy)	0.76	**0.87**
Sensibilidad (Recall) - Maligno	0.80	**0.93**
F1-Score - Maligno	0.82	**0.91**
Métricas a Nivel de Paciente		
Recognition Rate (RR)	75.11%	**88.48%**
Winner Takes All (WTA)	80.25%	**91.36%**

VII. Discusión

A. Análisis Comparativo del Rendimiento de las CNNs estudiadas

La evaluación experimental revela una dicotomía clara entre las dos estrategias abordadas. La arquitectura ResNet18, impulsada por la transferencia de aprendizaje, demostró un desempeño superior en basicamente todas las métricas críticas frente a la CNN personalizada entrenada desde cero lo cual se puede verificar en la tabla 1 I. como en las gráficas de de Curva ROC 10 12. y las matrices de confusiones para ambos modelos 9.

Este resultado valida la hipótesis de que, en conjuntos de datos histopatológicos de tamaño moderado como BreaKHis (aprox. 7,900 imágenes), la capacidad de extracción de características aprendida previamente en ImageNet (texturas, bordes y formas complejas) es más determinante que la especialización de una arquitectura ligera. Mientras que la CNN personalizada sufrió para generalizar patrones complejos (f1-score benigno de 0.65), ResNet18 logró una representación más robusta del espacio de características.

B. Análisis Detallado de ResNet18

Dada su superioridad, el análisis clínico se centra en el comportamiento de ResNet18. La configuración final, que combinó normalización estándar de ImageNet, *Focal Loss* implícito (vía ponderación de clases) y *Data Augmentation*, alcanzó el mejor compromiso entre sensibilidad y precisión.

1) Desempeño global y riesgo clínico: La matriz de confusión del modelo ResNet18 evidencia una alta eficacia en la tarea prioritaria: la detección de malignidad. El modelo clasificó correctamente 491 de 530 muestras malignas, resultando en una sensibilidad (*Recall*) de 0.93. En contraste, la especificidad para la clase benigna se situó alrededor de 0.75.

Desde una perspectiva clínica, este sesgo hacia la sensibilidad es preferible y deliberado. En sistemas de Diagnóstico Asistido por Computadora (CAD), el costo de un falso negativo (omitir un cáncer existente) es inmensamente mayor al de un falso positivo (solicitar una biopsia adicional confirmatoria). El modelo demuestra un comportamiento conservador, priorizando no pasar por alto lesiones malignas, aun a costa de sobreclasificar algunas lesiones benignas confusas.

La curva ROC respalda este comportamiento, manteniéndose claramente por encima de la diagonal con un Área Bajo la Curva (AUC) estimada superior a 0.90, lo que

indica una excelente capacidad de discriminación independientemente del umbral de decisión.

2) Sensibilidad a la Magnificación: Un hallazgo crucial, heredado del análisis exploratorio, es la variabilidad del desempeño según el factor de aumento. Se observa que el modelo tiende a obtener mejor sensibilidad en magnificaciones intermedias y altas (200X y 400X), donde las estructuras celulares y nucleares son claramente visibles.

Por el contrario, se detecta una degradación del rendimiento en 40X. Esto sugiere que, a baja resolución, la pérdida de detalle en la morfología nuclear dificulta la distinción entre tejidos sanos y patológicos, dependiendo más de la arquitectura tisular general, la cual puede ser ambigua. Esto plantea la necesidad futura de explorar arquitecturas *multi-escala* que integren información global (40X) y local (400X) simultáneamente.

C. Impacto de la Agregación por Paciente

Uno de los resultados más contundentes del estudio es la validación de la estrategia de agregación *patient-wise*. Mientras que a nivel de imagen individual (biopsia única) la exactitud se estancó en 87.00%, al agregar las predicciones de todas las imágenes pertenecientes a un mismo paciente, el rendimiento mejoró drásticamente.

El *Recognition Rate* (promedio de aciertos) subió a 88.48%, y mediante la estrategia de votación mayoritaria (*Winner Takes All*), se alcanzó una exactitud final de **91.36%**. Este salto confirma que los errores del modelo son mayoritariamente estocásticos y no sistemáticos: al tener múltiples "vistas" del tumor de un mismo paciente, el sistema es capaz de corregir sus propios fallos puntuales, superando el umbral de excelencia del 90% requerido para herramientas de apoyo diagnóstico fiables.

D. Limitaciones y Desafíos del Dominio

A pesar de los resultados prometedores, se identificaron factores limitantes que deben abordarse en iteraciones futuras:

1) **Heterogeneidad Intra-clase:** La clase "maligna" agrupa subtipos muy diversos (Ductal, Lobular, Mucinoso, Papilar). Es difícil para una sola red capturar todas estas variantes morfológicas con la misma eficacia sin un entrenamiento estratificado más granular.
2) **Variabilidad de Tinción:** Se observó cierto sobreajuste a patrones de color específicos. Las variaciones cromáticas inherentes a la preparación de las láminas (H&E) en diferentes laboratorios pueden afectar la generalización. La incorporación de técnicas de Normalización de Tinción (*Stain Normalization*) sería el siguiente paso lógico para mitigar este sesgo.
3) **Calibración Probabilística:** La elección de un umbral fijo de 0.5 puede no ser óptima para todos los subtipos. La ausencia de una calibración explícita sugiere que el modelo podría beneficiarse de un ajuste de umbral post-entrenamiento (*Temperature Scaling*) para alinear mejor las probabilidades predichas con la confianza real del diagnóstico.

VIII. Conclusión

Este trabajo presentó un pipeline completo para la clasificación de tumores en imágenes histopatológicas de cáncer de mama utilizando el conjunto BreakHis. Se compararon dos modelos, una CNN tradicional entrenada desde cero y una ResNet18 con *transfer learning*, integrando normalización de tinciones, aumentación avanzada y técnicas de balanceo por clase y subtipo.

Los resultados muestran que ResNet18, combinada con normalización de Macenko, Focal Loss y muestreo ponderado, alcanza un AUC cercano a 0.93, una sensibilidad para malignos alrededor de 0.93 y una exactitud global de 0.87. Al agregar las predicciones por paciente mediante voto mayoritario, la exactitud supera el 91 %, lo que sugiere un comportamiento clínicamente prometedor. La CNN desde cero, aunque útil como referencia, presenta menor capacidad de discriminación y mayor variabilidad entre pacientes.

Como trabajo futuro se propone explorar arquitecturas multi escala específicas por magnificación, estrategias de calibración probabilística y técnicas de explicabilidad más avanzadas, con el fin de fortalecer la interpretación clínica de las predicciones y mejorar el rendimiento en subtipos tumorales raros.

IX. Contribuciones

A. Eduardo Tello

Configuración de la metodología del proyecto, gestión del repositorio de código y apoyo en la discusión de resultados y redacción de la conclusión.

B. Abel Escobar

Implementación y entrenamiento de la CNN personalizada, diseño de las estrategias de *data augmentation*, y manejo adecuado de datos para evitar el data leakage dada la compleja estructura de archivos del dataset. Asimismo, contribuyó con la preparación de las figuras y gráficos para ambas CNNs.

C. Adrián Sandoval

Encargado de la revisión general de redacción del informe. Realizó los primeros avances sobre el mismo.

D. Luis Romero

Análisis exploratorio de datos, preparación de las estadísticas descriptivas del conjunto BreakHis y apoyo en la redacción de la sección de metodología.

Diseño del pipeline de ResNet18, implementación de la normalización de tinciones y del esquema de balanceo por clase y subtipo.

X. Bibliografía

- Sung, H., Ferlay, J., Siegel, R. L., Laversanne, M., Soerjomataram, I., Jemal, A., & Bray, F. (2021). Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. CA: A Cancer Journal for Clinicians, 71(3), 209–249. https://doi.org/10.3322/caac.21660
- Jiang, B., Bao, L., He, S., Chen, X., Jin, Z., & Ye, Y. (2024). Deep learning applications in breast cancer histopathological imaging: Diagnosis, treatment and prognosis. Breast Cancer Research, 26, 137. https://doi.org/10.1186/s13058-024-01895-6
- Zhu, Z., Zhang, Y., Liu, X., Li, H., Wang, H., & Xu, Y. (2023). A survey of convolutional neural network in breast cancer. Computer Modeling in Engineering & Sciences, 137(3), 2615–2649. https://doi.org/10.32604/cmes.2023.026479
- Spanhol, F. A., Oliveira, L. S., Petitjean, C., & Heutte, L. (2016). A dataset for breast cancer histopathological image classification. IEEE Transactions on Biomedical Engineering, 63(7), 1455–1462. https://doi.org/10.1109/TBME.2015.2496264
- de Matos, J., de Souza Britto, A., de Oliveira, L. E. S., & Koerich, A. L. (2019). Texture CNN for histopathological image classification. En 2019 IEEE 32nd International Symposium on Computer-Based Medical Systems (CBMS) (pp. 580–583). IEEE. https://doi.org/10.1109/CBMS.2019.00121

XI. Apéndice

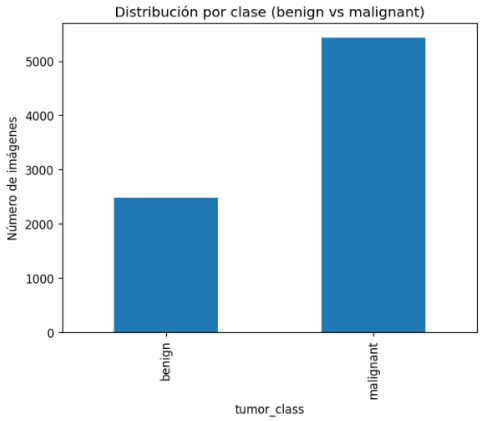

Fig. 1: Distribución por clase (benign vs malignant).

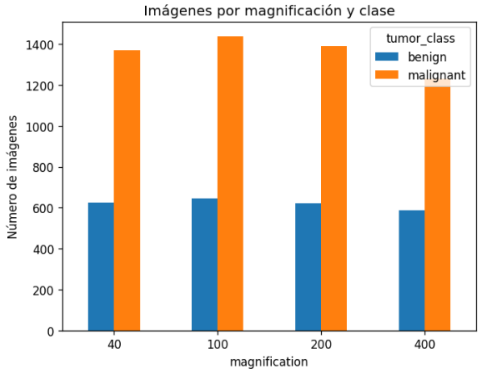

Fig. 2: Distribución conjunta por magnificación y clase.

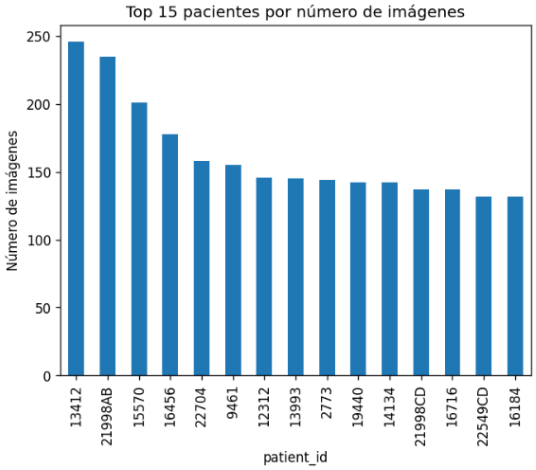

Fig. 3: Top 15 pacientes según número de imágenes.

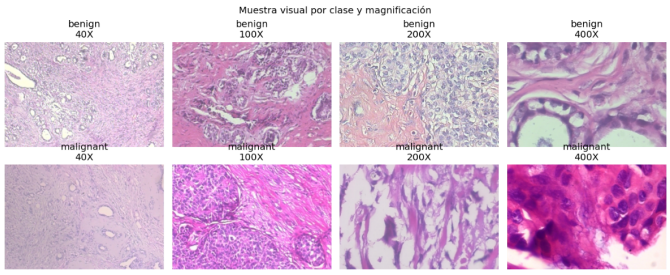

Fig. 4: Muestras visuales por clase y nivel de magnificación.

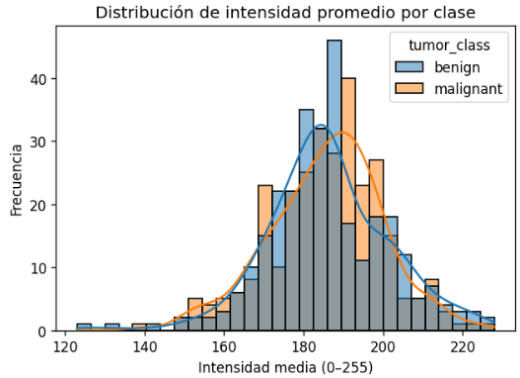

Fig. 5: Distribución de intensidad promedio por clase.

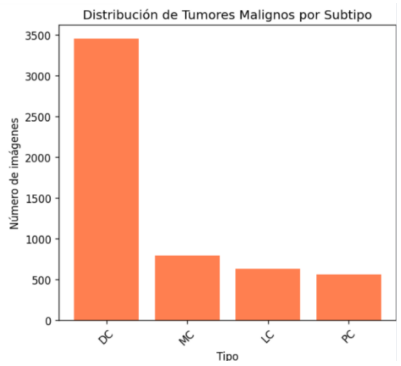

Fig. 6: Distribución de tumores benignos por subtipo.

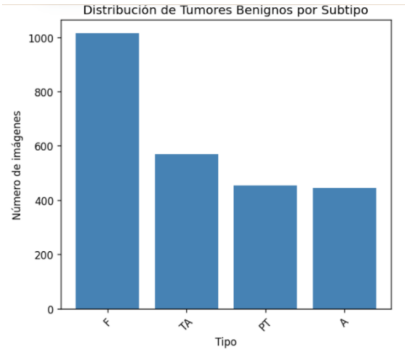

Fig. 7: Distribución de tumores malignos por subtipo.

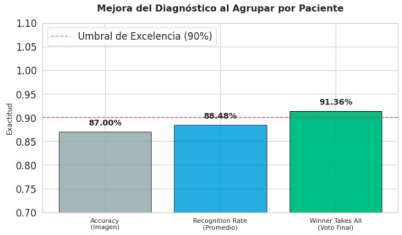

Fig. 8: Mejora del diagnóstico por paciente

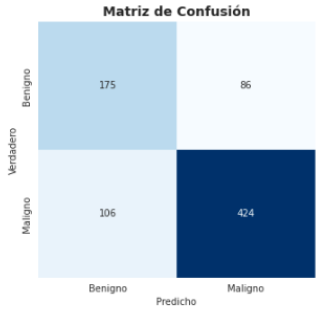

Fig. 11: Matriz de confusión de CNN personalizada

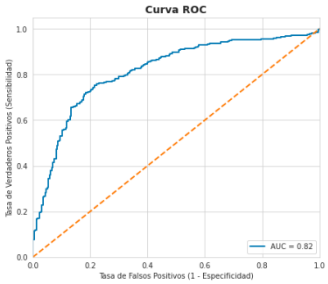

Fig. 12: CURVA ROC - CNN personalizada

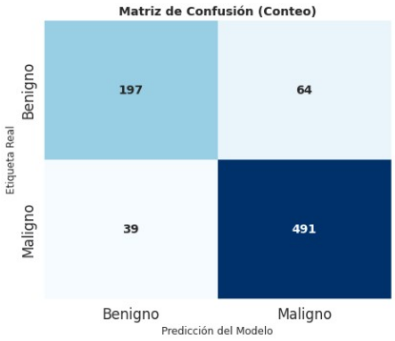

Fig. 9: Matriz de confusión ResNet18

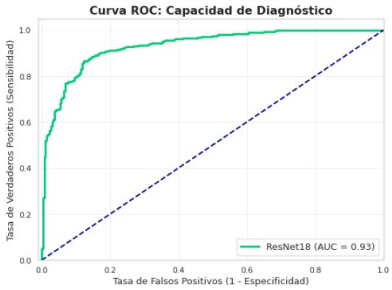

Fig. 10: Curva ROC - ResNet18